

Mini aplicacao de RAG com Python

Problema: como responder melhor usando documentos de apoio.

- LLMs podem responder sem contexto suficiente.
- Isso aumenta o risco de respostas vagas ou alucinacoes.
- A proposta foi recuperar trechos relevantes antes da geracao.

Pergunta central

Como construir uma aplicacao simples que use bibliotecas da Hugging Face para buscar contexto e gerar uma resposta mais confiavel?



Pipeline da solucao

RAG = recuperacao + geracao.

1. Base de textos

Pequeno conjunto de documentos sobre RAG, embeddings e modelos.


-> res

2. Recuperacao

Embeddings com all-MiniLM-L6-v2 e similaridade cosseno para buscar os trechos mais relevantes.

3. Geracao

Contexto recuperado enviado ao google/flan-t5-base para produzir a resposta em linguagem natural.



RESULTADO

Execucao e conclusao

O notebook foi executado e produziu uma resposta com contexto recuperado.

Saida observada

Documentos recuperados com score de similaridade.
Contexto enviado ao modelo.
Resposta gerada a partir desse contexto.

Pergunta testada: Como o RAG ajuda a reduzir alucinacoes em modelos de linguagem?

Conclusao

RAG melhora o controle sobre a resposta, porque o modelo nao depende apenas do conhecimento interno aprendido no treino.

A tecnica e util quando existe uma base propria de textos e queremos respostas mais fundamentadas.